ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Nguyễn Đức Khánh

ENHANCING OBJECT DETECTION PERFORMANCE UNDER FOGGY CONDITIONS THROUGH FUSION DOMAIN ADAPTATION

KHOÁ LUẬN TỐT NGHIỆP

Ngành: Khoa học máy tính

HÀ NỘI - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

NGUYỄN ĐỨC KHÁNH

ENHANCING OBJECT DETECTION PERFORMANCE UNDER FOGGY CONDITIONS THROUGH FUSION DOMAIN ADAPTATION

KHOÁ LUẬN TỐT NGHIỆP

Ngành: Khoa học máy tính

Cán bộ hướng dẫn: TS. Nguyễn Đức Anh

Cán bộ đồng hướng dẫn: ThS. Phạm Đức Anh

HÀ NỘI - 2026

VIETNAM NATIONAL UNIVERSITY, HANOI
UNIVERSITY OF ENGINEERING AND TECHNOLOGY

Nguyen Duc Khanh

ENHANCING OBJECT DETECTION PERFORMANCE UNDER FOGGY CONDITIONS THROUGH FUSION DOMAIN ADAPTATION

BACHELOR'S THESIS

Major: Computer Science

Supervisor: Dr. Nguyen Duc Anh

Co-Supervisor: M.Sc. Pham Duc Anh

HANOI - 2026

Lời cảm ơn

Lời đầu tiên, tôi xin bày tỏ lòng biết ơn sâu sắc tới TS. Nguyễn Đức Anh. Trong suốt quá trình học tập và thực hiện khóa luận, thầy đã tận tâm hướng dẫn và chia sẻ cho tôi những kiến thức chuyên môn giá trị cùng nhiều kinh nghiệm thực tiễn quý báu. Không chỉ dừng lại ở việc truyền đạt kiến thức, thầy còn định hướng cho tôi phương pháp tư duy khoa học và cách tiếp cận nghiên cứu hiệu quả, giúp tôi từng bước hoàn thiện đề tài một cách tốt nhất. Những bài học và kinh nghiệm mà thầy truyền đạt sẽ luôn là hành trang quan trọng, làm nền tảng cho sự phát triển của tôi trong chặng đường sắp tới.

Bên cạnh đó, tôi xin chân thành cảm ơn quý thầy cô, cán bộ, anh chị và bạn bè tại Trường Đại học Công nghệ đã luôn đồng hành và tạo điều kiện thuận lợi để tôi được học tập, nghiên cứu và hoàn thành khóa luận. Sự hỗ trợ và sẻ chia của mọi người trong suốt thời gian qua là nguồn động lực lớn lao, giúp tôi không ngừng nỗ lực và hoàn thiện bản thân.

Cuối cùng, tôi xin gửi lời tri ân chân thành tới gia đình, những người luôn ở bên cạnh, yêu thương, khích lệ và ủng hộ tôi vô điều kiện. Chính sự tin tưởng và động viên của gia đình đã tiếp thêm cho tôi nghị lực để vượt qua những thử thách và hoàn thành tốt quá trình học tập của mình.

Lời cam đoan

Tôi tên là Nguyễn Đức Khánh, sinh viên lớp K67I-CS2, ngành Khoa học máy tính. Tôi xin cam kết rằng khóa luận tốt nghiệp của tôi với đề tài "Enhancing Object Detection Performance under Foggy Conditions through Fusion Domain Adaptation" là kết quả nghiên cứu do chính tôi thực hiện và chưa từng được sử dụng để bảo vệ tại bất kỳ cơ sở đào tạo đại học nào, bao gồm cả Trường Đại học Công nghệ. Tôi khẳng định rằng trong quá trình thực hiện đề tài, tôi không sao chép nội dung từ bất kỳ nguồn tài liệu nào, cũng như không sử dụng kết quả nghiên cứu của cá nhân hay tổ chức khác khi chưa được trích dẫn rõ ràng. Công trình này được tôi triển khai dưới sự hướng dẫn của TS. Nguyễn Đức Anh và không bao gồm bất kỳ phần mã nguồn nào bị sao chép hoặc chỉnh sửa từ cá nhân hay đơn vị khác mà không có sự cho phép hợp lệ. Toàn bộ số liệu, kết quả và tài liệu tham khảo được sử dụng trong khóa luận đều đảm bảo tính trung thực, chính xác và đã được trích dẫn đầy đủ theo quy định. Nếu có bất kỳ vi phạm nào liên quan đến những cam kết nêu trên, tôi xin hoàn toàn chịu trách nhiệm theo quy định của Trường Đại học Công nghệ.

Hà Nội, ngày tháng năm 2026

Sinh viên

Nguyễn Đức Khánh

Tóm tắt

Tóm tắt nội dung KL tốt nghiệp: Bài toán, phương pháp giải quyết, kết quả đạt được

Từ khóa: Liệt kê 3-5 từ khoá liên quan

Abstract

Summary of the graduation thesis: The problem statement, the proposed approach, and the achieved results.

Keywords: Liệt kê 3-5 từ khoá liên quan

Mục lục

Lời cảm ơn

Lời cam đoan **i**

Tóm tắt **ii**

Abstract **iii**

Mục lục **iv**

Danh sách hình vẽ **vi**

Danh sách bảng **vii**

Danh mục các từ viết tắt **viii**

Chương 1 Đặt vấn đề **1**

Chương 2 Cơ sở lý thuyết **5**

2.1 Object detection 5

2.2 Domain adaptation 6

2.3 Knowledge distillation framework 7

2.4 Standard finetune object detection methods 8

2.5 Domain adaptive object detection methods 8

Chương 3 Phương pháp đề xuất **11**

3.1 Mô hình Mean Teacher 11

3.2 Ảnh tạo sinh chuyển đổi miền 12

3.3 Hàm mất mát chưng cất 15

3.4 Hàm mất mát nhất quán 16

3.5 Mô-đun học đảo ngược 16

3.6 Tối ưu tổng quan 17

Chương 4 Thực nghiệm và đánh giá **19**
4.1 Câu hỏi nghiên cứu 19
4.2 Dữ liệu và thiết lập thực nghiệm 19
4.3 Các phương pháp đối sánh 19
4.4 Độ đo đánh giá 19
4.5 Kết quả thực nghiệm 20
4.6 Phân tích và thảo luận kết quả 20

Kết luận **21**

Tài liệu tham khảo **22**

Danh sách hình vẽ

1.1 Mô hình tán xạ khí quyển (Atmospheric Scattering Model). Ánh sáng từ nguồn chiếu vào cảnh vật, sau đó một phần bị phản xạ, một phần bị tán xạ bởi các hạt sương và hấp thụ khi truyền đến cảm biến. Ngoài ra, ánh sáng môi trường do tán xạ nhiều lần cũng đi thẳng đến cảm biến, làm ảnh thu được sáng trắng và giảm độ tương phản. . . . 2

2.1 Minh họa cơ chế học đặc trưng bất biến miền bằng Gradient Reversal Layer (GRL). Mô hình gồm ba phần: bộ trích chọn đặc trưng $\mathcal{G}_f$, bộ dự đoán nhãn $\mathcal{G}_y$, và bộ phân loại miền $\mathcal{G}_d$. GRL đảo chiều gradient từ nhánh phân biệt miền để ép $\mathcal{G}_f$ học đặc trưng sao cho không thể phân biệt giữa miền nguồn và miền mục tiêu. Cách tiếp cận này giúp mô hình học được các đặc trưng chung, giảm ảnh hưởng khác biệt miền và tăng tính tổng quát. 10

3.1 Kiến trúc tổng quan của phương pháp FusionDA. **Pha 1:** tạo các ảnh với phong cách miền khác để giảm khoảng cách miền. **Pha 2:** huấn luyện model YOLO26 với Mean Teacher framework kết hợp cùng mô-đun sử dụng GRL. Các luồng input (màu khác nhau) kết hợp cùng các hàm loss giúp hỗ trợ việc học bán giám sát 12

3.2 Ví dụ minh họa quá trình chuyển đổi miền, trong đó (a) là hình ảnh nguồn $\mathbf{I}^s$, (b) là hình ảnh đích thật $\mathbf{I}^t$, (c) là hình ảnh dạng đích được tổng hợp $\mathbf{I}^{sf}$, và (d) là hình ảnh dạng nguồn được khử sương $\mathbf{I}^{tf}$ . . . 13

Danh sách bảng

Danh mục các từ viết tắt

Từ viết tắt	Cụm từ đầy đủ	Ý nghĩa / Mô tả
BiLSTM	Bidirectional Long Short Term Memory	Mô hình bộ nhớ dài hạn ngắn hạn hai chiều
BO	Buffer Overflow	Lỗi tràn bộ đệm

Chương 1

Đặt vấn đề

Nhận diện vật thể ngoài trời trong điều kiện thời tiết khắc nghiệt, đặc biệt là sương mù, hiện là một bài toán cấp thiết và mang tính nền tảng trong lĩnh vực thị giác máy tính, đóng vai trò quyết định đến độ an toàn của các hệ thống xe tự hành và giám sát thông minh. Trong khi các mô hình nhận diện hiện đại như dòng YOLO hay Faster R-CNN đạt hiệu suất gần như tuyệt đối trong môi trường quang đãng, độ chính xác của chúng suy giảm nghiêm trọng khi triển khai trong môi trường sương mù do hiện tượng tán xạ ánh sáng 1.1 và giảm độ tương phản [1] [2]. Để giải quyết vấn đề này, các giải pháp tiêu biểu hiện nay tập trung vào hai hướng chính: (1) Khôi phục ảnh (Image Dehazing) trước khi đưa vào mô hình nhận diện, và (2) Huấn luyện mô hình trên dữ liệu sương mù tổng hợp (Synthetic Foggy Data) [3] [4]. Tuy nhiên, so sánh thực nghiệm cho thấy các phương pháp Dehazing thường làm mất mát thông tin ngữ nghĩa quan trọng, trong khi các phương pháp tạo dữ liệu tổng hợp hiện tại, như pipeline của dataset Cityscapes vẫn chưa mô phỏng được tính chất vật lý phức tạp của môi trường thực. Cụ thể, các giải pháp tiêu biểu này gặp phải 2 vấn đề chính tồn tại gồm vấn đề thiếu hụt tính chân thực vật lý dẫn đến sai lệch miền dữ liệu và vấn đề mô hình không học được tổng quát về các đặc trưng của sương mù nếu chỉ theo phương pháp truyền thống.

Đối với vấn đề sai lệch phân phối dữ liệu, đây là thách thức nền tảng khiến hiệu suất mô hình suy giảm nghiêm trọng khi chuyển từ dữ liệu huấn luyện sang môi trường thực tế. Sự khác biệt rõ rệt về phong cách ảnh, điều kiện chiếu sáng và chất lượng ảnh giữa miền nguồn và miền đích tạo ra một khoảng cách miền lớn [5]. Các phương pháp học máy truyền thống thường giả định rằng dữ liệu huấn luyện tuân theo phân phối đồng nhất, vì vậy chúng thất bại trong việc tổng quát các đặc trưng giữ nguyên trước các thay đổi về thời tiết hay môi trường. Nhiều nghiên cứu gần đây cố gắng khắc phục bằng cách căn chỉnh đặc trưng (từ cấp độ tổng thể đến cấp độ chi tiết) giữa hai miền, tuy nhiên sự chênh lệch ở cấp độ hình ảnh vẫn gây ra sai lệch thống kê lớn ở cấp pixel. Các kết quả cho thấy những khác biệt thống kê cấp pixel nếu không được giải quyết triệt để sẽ làm giảm khả năng khái

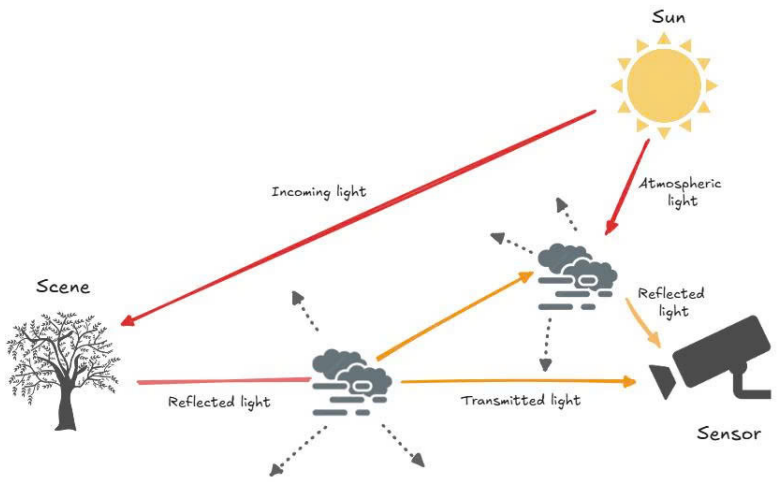

Hình 1.1: Mô hình tán xạ khí quyển (Atmospheric Scattering Model). Ánh sáng từ nguồn chiếu vào cảnh vật, sau đó một phần bị phản xạ, một phần bị tán xạ bởi các hạt sương và hấp thụ khi truyền đến cảm biến. Ngoài ra, ánh sáng môi trường do tán xạ nhiều lần cũng đi thẳng đến cảm biến, làm ảnh thu được sáng trắng và giảm độ tương phản.

quát hóa của mô hình. Bên cạnh đó, các phương pháp học đối nghịch phổ biến sử dụng Gradient Reversal Layer (GRL) cũng gặp khó khăn trong tối ưu hóa và hội tụ do tính chất cạnh tranh của quá trình học [6]. Kết quả là mô hình khó có thể học được biểu diễn đối tượng chính xác trong điều kiện tầm nhìn bị hạn chế. Do đó, cần phát triển một cơ chế thích nghi miền hiệu quả hơn, có khả năng thu hẹp khoảng cách phân phối này một cách triệt để.

Mặc dù việc thu thập ảnh thô trong thực tế có thể khả thi, nhưng quá trình gán nhãn thủ công lại tốn kém rất nhiều thời gian và chi phí. Sự khan hiếm dữ liệu được gán nhãn khiến mô hình khó học được các đặc trưng tổng quát, nhất là khi phải đối mặt với nhiễu động nghiêm trọng từ môi trường. Đặc biệt trong các điều kiện khắc nghiệt như sương mù dày đặc, việc xác định chính xác đường biên của vật thể bằng mắt thường gần như bất khả thi, dẫn đến mức nhiễu cao trong nhãn thực tế. Hầu hết các phương pháp thích nghi miền không giám sát hiện tại cố gắng giải quyết vấn đề này bằng cách chỉ sử dụng dữ liệu nguồn có nhãn để căn chỉnh phân phối đặc trưng cấp tổng thể [7]. Tuy nhiên, cách tiếp cận đó bỏ qua nguồn thông tin phong phú về đặc trưng đối tượng (instance-level features) ẩn chứa trong dữ liệu miền đích chưa gán nhãn. Thiếu đi cơ chế khai thác tri thức từ miền đích khiến mô hình không thể tự điều chỉnh và tinh chỉnh dự đoán trên miền mới, làm giảm đáng kể khả năng thích ứng và độ tin cậy khi triển khai thực tế. Thực tế cho

thấy việc áp dụng cơ chế học bán giám sát (semi-supervised), sử dụng thêm dữ liệu không nhãn của miền đích, là chìa khóa then chốt để nâng cao hiệu năng trên miền mới, điều mà các phương pháp truyền thống chưa giải quyết triệt để [8].

Để giải quyết các hạn chế nêu trên, nghiên cứu đề xuất phương pháp gọi là FusionDA, một cơ chế thích nghi miền bán giám sát vào kiến trúc mô hình phát hiện vật thể một giai đoạn. Pipeline của phương pháp thể hiện trong hình 3.1. Tư tưởng chính của phương pháp là kết hợp kỹ thuật chuyển đổi phong cách ảnh để thu hẹp khoảng cách miền ở cấp độ hình ảnh, đồng thời sử dụng cơ chế chưng cất tri thức để khai thác thông tin từ dữ liệu đích không nhãn.

- Đầu vào là: Tập ảnh nguồn có nhãn đầy đủ và tập ảnh đích hoàn toàn không có nhãn, cùng các tập ảnh tạo ra từ 2 tập ảnh này
- Đầu ra là: Mô hình nhận diện vật thể có khả năng hoạt động chính xác và ổn định trên miền đích

Phương pháp được thực hiện qua 3 bước chính. Bước 1, phương pháp sử dụng mô hình dự đoán độ sâu kết hợp công thức tán xạ khí quyển và mô hình khử sương để sinh ra các dữ liệu giả khác miền . Bước này giúp đồng bộ hóa phân phối phong cách giữa hai miền, giải quyết trực tiếp vấn đề sai lệch miền dữ liệu ngay từ đầu vào. Bước 2, áp dụng framework Mean Teacher để sinh nhãn giả (pseudo-labels) chất lượng cao trên dữ liệu đích. Việc này cho phép mô hình tự học các đặc trưng đối tượng quan trọng ngay cả khi thiếu hụt dữ liệu gán nhãn thủ công. Bước 3, phương pháp kết hợp thêm mô đun đảo ngược đạo hàm nhằm mục đích tăng cường cho khả năng tổng quát hóa của mô hình trên cả hai miền dữ liệu.

Để chứng minh hiệu quả phương pháp đề xuất, thực nghiệm được tiến hành trên bộ dữ liệu Citiscapes và sử dụng mô hình YOLO26 phiên bản small cho quá trình huấn luyện và đánh giá. Phương pháp so sánh bao gồm phương pháp huấn luyện truyền thống và việc kết hợp các module. Kết quả thực nghiệm cho thấy sự vượt trội của phương pháp đề xuất so với các baseline. Cụ thể, trên thước đo mAP@0.5, trong khi phương pháp baseline tốt nhất hiện nay ...

Tóm lại, các đóng góp chính của bài báo được tóm tắt như sau: Nghiên cứu đề xuất FusionDA để giải quyết triệt để vấn đề sai lệch miền. Tư tưởng chính là kết hợp thêm các module có chức năng riêng biệt để cải thiện hiệu suất. Ngoài ra, nghiên cứu còn cung cấp thêm phương pháp sinh dữ liệu để giải quyết thiếu hụt sự đa

dạng trong dữ liệu sương mù tổng hợp. Nghiên cứu thực hiện đánh giá toàn diện phương pháp đề xuất trên các bộ dữ liệu chuẩn Citiscapes, chứng minh khả năng cải thiện độ chính xác nhận diện vật thể vượt trội so với các phương pháp SOTA.

Phần còn lại của báo cáo được trình bày như sau. Chương 2 trình bày cơ sở lý thuyết với các kiến thức nền tảng và định nghĩa bài toán. Chương 3 mô tả chi tiết phương pháp đề xuất. Chương 4 cung cấp các thiết lập thực nghiệm, kết quả so sánh và thảo luận. Cuối cùng là kết luận và đề xuất hướng phát triển tương lai.

Chương 2

Cơ sở lý thuyết

2.1 Object detection

Object detection đã có lịch sử phát triển lâu dài, dẫn đến sự xuất hiện của rất nhiều phương pháp khác nhau. Các nghiên cứu kinh điển [9] [10] thường mô hình hóa bài toán object detection như một bài toán phân loại cửa sổ trượt (sliding window classification). Sự trỗi dậy của deep convolutional neural networks (CNNs) [11] bắt nguồn từ lĩnh vực object detection, nơi những thành công ban đầu của CNN đã tạo nên một sự chuyển dịch mạnh mẽ về mặt phương pháp luận. Trong phát hiện vật thể, tồn tại hai hướng chính: two-stage và one-stage. Các mô hình two-stage (như R-CNN, Fast/Faster R-CNN) bắt đầu bằng bước tạo đề xuất vùng (Region Proposal) rồi mới phân loại; cách này mang lại độ chính xác cao đặc biệt với vật thể nhỏ, nhưng giá của nó là tốc độ thấp và pipeline phức tạp. Ngược lại, one-stage (như YOLO, SSD, RetinaNet) coi việc phát hiện như bài toán hồi quy duy nhất, tức dự đoán trực tiếp hộp giới hạn và nhãn trong cùng một lần lan truyền qua mạng [12]. Ưu thế của one-stage là tốc độ rất cao, thích hợp cho hệ thống thời gian thực. Chẳng hạn YOLO đã chứng minh có thể duy trì mấy chục FPS trong khi vẫn đạt AP cao hơn hẳn các detector thời gian thực khác cùng thời. Trong khi RetinaNet giới thiệu hàm mất mát Focal Loss để cân bằng lớp nhằm tăng tính chính xác, YOLO vẫn nổi trội về tốc độ. Trong khuôn khổ này, nghiên cứu chọn YOLO vì nó định hướng tới phân tích thời gian thực, đặc biệt với các biến thể mới nhất có thể cân đối tốt giữa tốc độ và độ chính xác. Một bộ object detector điển hình bao gồm ba thành phần: backbone, neck, và head. Backbone, được xây dựng từ các lớp tích chập, có nhiệm vụ trích xuất và mã hóa các đặc trưng trong ảnh. Thông thường, backbone được huấn luyện trên các tập dữ liệu ảnh lớn. Neck nằm giữa backbone và head, với nhiệm vụ chính là học các đặc trưng đa tỉ lệ bằng cách sử dụng các kiến trúc như Feature Pyramid Network [13], Path Aggregation Network [14], v.v. Head nhận đầu ra từ neck và thực hiện dự đoán bounding boxes cũng như xác suất của c lớp. Đầu ra của một object detector là một vector bao

gồm các thành phần được mô tả trong Công thức 2.1

$$y^T = [p_0, \underbrace{\langle t_x, t_y, t_w, t_h \rangle}_{\text{bounding box}}, \quad \underbrace{\langle p_1, p_2, ..., p_c \rangle}_{\text{predicted class probabilities}} \quad] \tag{2.1}$$

Trong đó p_0 là xác suất dự đoán có đối tượng trong bounding box; t_x, t_y là tọa độ tâm của bounding box; t_w, t_h là độ rộng và chiều cao của bounding box; $p_1, p_2, .., p_c$ à vector dự đoán xác suất thuộc c lớp.

2.2 Domain adaptation

Trong các mô hình học máy truyền thống, một giả định cơ bản là dữ liệu huấn luyện và dữ liệu kiểm thử được rút ra từ cùng một phân phối thống kê. Điều này cho phép mô hình học được một hàm dự đoán h có khả năng tổng quát tốt. Bài toán được mô tả dưới dạng tối ưu hoá rủi ro kỳ vọng:

$$R(h) = \mathbb{E}_{(x,y)\sim P(x,y)}[\ell(h(x), y)],$$

trong đó ℓ là hàm mất mát đo độ sai lệch giữa dự đoán và nhãn thực. Tuy nhiên, trong nhiều ứng dụng thực tế như thị giác máy tính, xử lý tín hiệu hay phân tích hành vi, điều kiện dữ liệu thay đổi liên tục theo môi trường, thiết bị, thời gian hoặc phong cách. Khi đó, phân phối dữ liệu mới không còn giống với phân phối được dùng để huấn luyện mô hình. Hiện tượng này được gọi là domain shift [15].

Mỗi miền dữ liệu được mô tả bởi bộ ba $D = \{\mathbf{X}, \mathbf{Y}, P(x, y)\}$, với $\mathbf{X}$ là không gian đặc trưng, $\mathbf{Y}$ là không gian nhãn và $P(x, y)$ là phân phối chung. Cho một miền nguồn S và một miền đích T, domain shift xuất hiện khi $P_S(x, y) \neq P_T(x, y)$. Trong trường hợp này, mô hình học từ miền nguồn có thể hoạt động kém trên miền đích. Mục tiêu của domain adaptation là học một mô hình từ dữ liệu miền nguồn sao cho mô hình này vẫn duy trì hiệu quả trên miền đích, ngay cả khi miền đích có ít nhãn hoặc không có nhãn. Rủi ro kỳ vọng trên miền đích có thể được viết lại theo phân phối của miền nguồn như sau:

$$R_T(h) = \mathbb{E}_{(x,y)\sim P_S(x,y)}\left[\frac{P_T(x, y)}{P_S(x, y)}\ell(h(x), y)\right].$$

Tỷ lệ giữa hai phân phối đóng vai trò như hệ số điều chỉnh giúp giảm sự khác biệt

giữa hai miền. Tuy nhiên, việc ước lượng đầy đủ phân phối $P_T(x, y)$ thường không khả thi do thiếu nhãn trong miền đích.

Một mô hình tiêu biểu của phương pháp đối kháng là Domain Adversarial Neural Network. Mô hình này bao gồm bộ trích đặc trưng G_f, bộ phân loại nhãn G_y và bộ phân biệt miền G_d. Mục tiêu tối ưu hoá được viết dưới dạng:

$$\min_{\theta_f,\theta_y} \max_{\theta_d} \left(\mathbf{L}_y(G_y(G_f(x)), y) - \lambda \mathbf{L}_d(G_d(G_f(x)), d) \right),$$

trong đó $\mathbf{L}_y$ là mất mát phân loại nhãn và $\mathbf{L}_d$ là mất mát phân biệt miền. Việc tối ưu theo hướng đối nghịch buộc G_f học các đặc trưng vừa có khả năng phân loại tốt vừa khó bị phân biệt theo miền, giúp giảm domain shift.

Như vậy, domain adaptation cung cấp một hướng tiếp cận quan trọng để xử lý sự thay đổi phân phối dữ liệu trong các hệ thống thực tế. Nhờ khả năng học đặc trưng bất biến miền, đặc biệt khi kết hợp với học sâu, domain adaptation có vai trò lớn trong các ứng dụng thị giác máy tính, xử lý ngôn ngữ tự nhiên và nhận dạng hành vi. Các phương pháp hiện đại tiếp tục mở rộng khả năng tổng quát hóa của mô hình, giúp chúng thích nghi tốt hơn với các môi trường dữ liệu đa dạng.

2.3 Knowledge distillation framework

Knowledge distillation là một kỹ thuật chuyển giao khả năng khái quát hóa từ một mô hình lớn và chính xác (teacher) sang một mô hình nhỏ và hiệu quả hơn (student) [16]. Thay vì chỉ huấn luyện student bằng hard labels, student được học từ soft output distribution của teacher, trong đó chứa thông tin về mức độ tương tự giữa các lớp mà one-hot labels không thể hiện. Logits của teacher và student được đưa qua hàm softmax với tham số temperature; khi temperature tăng, phân phối xác suất trở nên mềm hơn và phản ánh rõ hơn kiến thức của teacher về quan hệ giữa các lớp.

Hàm softmax có temperature cho logits của student z_i:

$$q_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}.$$

Teacher tạo ra soft targets:

$$p_i = \frac{\exp(v_i/T)}{\sum_j \exp(v_j/T)}.$$

Quá trình huấn luyện kết hợp hai hàm mất mát: soft-target cross-entropy tại temperature T và hard-target cross-entropy tại $T = 1$. Hàm mất mát tổng hợp:

$$\mathbf{L} = \alpha T^2 H(p_T, q_T) + \beta H(y, q_{T=1}).$$

Soft targets đóng vai trò như một dạng regularization mạnh, giúp student học được hành vi của teacher ngay cả khi dữ liệu ít hoặc không có nhãn, cho phép mô hình nhỏ đạt hiệu năng gần với mô hình lớn trong khi chi phí tính toán thấp và phù hợp cho triển khai thực tế.

2.4 Standard finetune object detection methods

Trong bối cảnh dữ liệu gán nhãn ngày càng phong phú và các mô hình học sâu ngày càng được cải tiến, phương pháp tinh chỉnh (fine-tuning) trở thành lựa chọn mặc định trong nhiều hệ thống phát hiện vật thể. Thay vì huấn luyện từ đầu, việc sử dụng lại các trọng số đã học từ mô hình tiền huấn luyện giúp rút ngắn thời gian huấn luyện, giảm yêu cầu tài nguyên và cải thiện hiệu năng ban đầu. Đặc biệt với các mạng hiện đại như YOLO26, chiến lược fine-tuning nếu được áp dụng hợp lý có thể mang lại hiệu suất rất cao ngay cả trong môi trường dữ liệu khác biệt.

Phương pháp tinh chỉnh trong phát hiện đối tượng thường bắt đầu từ một mô hình đã được huấn luyện trước trên tập dữ liệu lớn (ví dụ COCO) và điều chỉnh thêm cho phù hợp với tập dữ liệu mới. Đối với YOLO26, thông thường ta tái sử dụng phần backbone đã được tiền huấn luyện để trích xuất đặc trưng chung, trong khi chỉ huấn luyện lại phần head để nhận dạng các lớp đối tượng mới. Theo tài liệu hướng dẫn của YOLO26, việc đóng băng các lớp đầu và chỉ cập nhật tham số các lớp cuối giúp giảm đáng kể thời gian và tài nguyên huấn luyện, dù có thể làm giảm nhẹ độ chính xác cuối cùng. Cấu trúc chuẩn của YOLO26 gồm một backbone và một head. Khi tinh chỉnh, thường giữ nguyên tham số của backbone bằng cách đóng băng và chỉ huấn luyện lại head để thích ứng với số lớp hoặc miền mới.

2.5 Domain adaptive object detection methods

Khi các hệ thống phát hiện vật thể được triển khai vào môi trường thực tế, chúng thường gặp phải vấn đề sai lệch miền dữ liệu, hiện tượng mà dữ liệu triển khai có

khác biệt đáng kể so với dữ liệu dùng để huấn luyện. Khi miền huấn luyện (source) và miền kiểm thử (target) khác biệt đáng kể, các phương pháp thích nghi miền (Domain Adaptation) được sử dụng để giảm thiểu sự sụt giảm hiệu năng. Trong phần này, nghiên cứu đưa ra hai phương pháp nổi bật để so sánh với phương pháp đề xuất, một là phương pháp tổng quát áp dụng trên nhiều bài toán học máy, và một là kỹ thuật chuyên biệt cho bài toán phát hiện vật thể, cả hai đều đã được kiểm chứng về hiệu quả và được trích dẫn rộng rãi trong cộng đồng nghiên cứu.

Một hướng chung là mô hình Domain Adversarial Neural Network (DANN), được Ganin và cộng sự đề xuất [17]. DANN bổ sung một bộ phân loại miền và một lớp gradient reversal (đảo ngược gradient) vào mạng, huấn luyện đồng thời để nhận dạng đối tượng và đối kháng sao cho đặc trưng trích xuất ra khó bị phân biệt theo miền. Kết quả là, các đặc trưng học được vừa có khả năng phân biệt tốt cho nhiệm vụ chính, vừa bất biến với sự khác biệt giữa miền. Cách tiếp cận này đã chứng minh hiệu quả trong nhiều bài toán phân loại và có thể áp dụng tương tự cho phát hiện đối tượng nhằm tăng tính tổng quát khi chuyển đổi môi trường. Mạng DANN (Domain Adversarial Neural Network) DANN triển khai ý tưởng huấn luyện đa nhiệm kết hợp giữa nhiệm vụ chính (ví dụ nhận dạng) và một nhiệm vụ đối kháng nhận diện miền. Cụ thể, trong mạng DANN có thêm một lớp Gradient Reversal Layer nối với bộ phân loại miền; trong quá trình lan truyền ngược, lớp này nhân gradient với hệ số âm, buộc mạng học ra các đặc trưng bất biến với phân phối nguồn và đích. Nhờ vậy, mô hình được thúc đẩy tạo ra các đặc trưng vừa mang tính phân biệt cao cho bài toán chính, vừa không cho phép bộ phân loại miền phân biệt được miền của mẫu

Thích nghi miền cho phát hiện đối tượng sẽ gồm các phương pháp chuyên biệt cho bài toán phát hiện cũng ứng dụng tư tưởng adversarial để cân bằng miền ở các cấp độ khác nhau. Ví dụ, Chen và cộng sự (CVPR 2018) giới thiệu Domain Adaptive Faster R-CNN, trong đó thêm bộ phân loại miền tại hai cấp độ hình ảnh (image-level) và đối tượng (instance-level) trong Faster R-CNN để giảm sai khác miền [18]. Tiếp đó, Saito và cộng sự (CVPR 2019) đề xuất mô hình SWDA (Strong-Weak Domain Alignment) [19], thực hiện đối khớp phân phối miền với hai chiến lược: đối khớp yếu ở cấp toàn cục (chỉ tập trung vào những ảnh nguồn-đích có bố cục tương tự) và đối khớp mạnh ở cấp cục bộ (trên vùng đặc trưng nhỏ). Cả hai phương pháp này đều huấn luyện mạng phát hiện đối tượng trong khuôn khổ

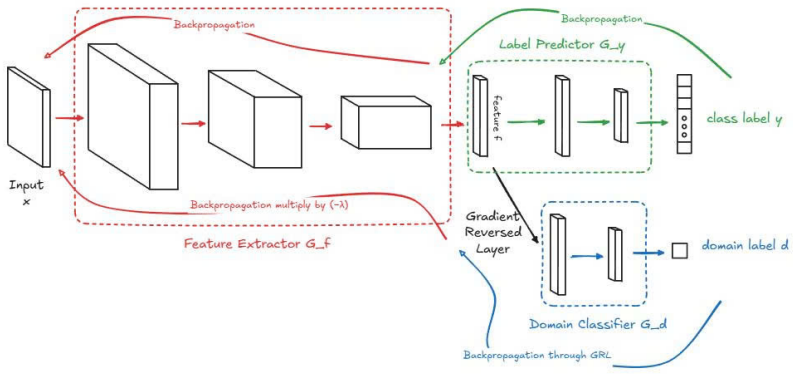

Hình 2.1: Minh họa cơ chế học đặc trưng bất biến miền bằng Gradient Reversal Layer (GRL). Mô hình gồm ba phần: bộ trích chọn đặc trưng $\mathcal{G}_f$, bộ dự đoán nhãn $\mathcal{G}_y$, và bộ phân loại miền $\mathcal{G}_d$. GRL đảo chiều gradient từ nhánh phân biệt miền để ép $\mathcal{G}_f$ học đặc trưng sao cho không thể phân biệt giữa miền nguồn và miền mục tiêu. Cách tiếp cận này giúp mô hình học được các đặc trưng chung, giảm ảnh hưởng khác biệt miền và tăng tính tổng quát.

đối kháng miền để trích xuất được đặc trưng bất biến miền, giúp cải thiện hiệu năng khi áp dụng trên tập dữ liệu mới mà không cần nhãn của miền đích.

Chương 3

Phương pháp đề xuất

Phương pháp FusionDA đề xuất được xây dựng dựa trên bộ phát hiện một giai đoạn (one-stage detector) là YOLO26. Phương pháp này bao gồm năm thành phần chính: mô hình Mean Teacher với khung chưng cất tri thức (knowledge distillation) để hướng dẫn việc cập nhật mô hình student hiệu quả; module discriminator để khiến backbone học được đặc trưng của các miền; các hình ảnh huấn luyện giả được tạo chéo (pseudo cross-generated) nhằm giảm thiểu sự khác biệt miền ở cấp độ hình ảnh; hàm mất mát chưng cất (distillation loss) được cập nhật để khắc phục sự sai lệch chéo miền; và hàm mất mát nhất quán (consistency loss) mới để giải quyết thêm vấn đề thiên kiến về tính đối tượng khác miền. Chi tiết về các mô-đun này được trình bày như sau.

3.1 Mô hình Mean Teacher

Mô hình Mean Teacher (MT) [20] ban đầu được đề xuất cho học bán giám sát (semi-supervised learning) trong phân loại hình ảnh. Nó bao gồm một cấu trúc chưng cất tri thức điển hình với hai kiến trúc mô hình giống hệt nhau. Đối với các tác vụ thích ứng miền, mô hình học sinh được huấn luyện với dữ liệu có nhãn trong miền nguồn sử dụng gradient descent optimizer. Theo thiết lập của mô hình MT, mô hình giáo viên được cập nhật bằng các trọng số trung bình trượt theo hàm mũ (EMA) từ mô hình học sinh. Cụ thể, giả sử rằng các tham số trọng số của mô hình học sinh và giáo viên được ký hiệu lần lượt là $\mathbf{P}_s$ và $\mathbf{P}_t$, nghiên cứu cập nhật $\mathbf{P}_t$ tại mỗi bước batch huấn luyện như sau:

$$\mathbf{P}_t = \gamma \mathbf{P}_t + (1 - \gamma)\mathbf{P}_s \tag{3.1}$$

trong đó γ là hệ số suy giảm theo hàm mũ (exponential decay). Giá trị hợp lý của nó gần bằng 1.0, thường nằm trong khoảng: 0.99, 0.999, v.v..

Khi áp dụng mô hình MT vào tác vụ phát hiện đối tượng chéo miền của nghiên cứu, nghiên cứu thiết lập các mẫu miền đích không nhãn $\mathbf{D}_t$ làm đầu vào duy nhất

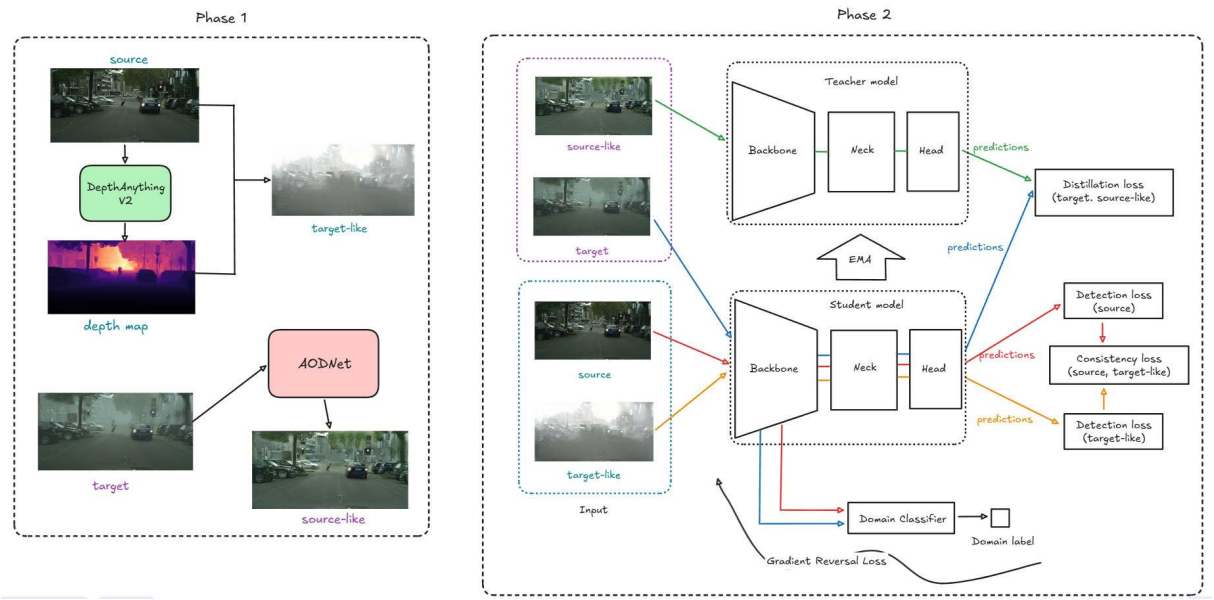

Hình 3.1: Kiến trúc tổng quan của phương pháp FusionDA. **Pha 1:** tạo các ảnh với phong cách miền khác để giảm khoảng cách miền. **Pha 2:** huấn luyện model YOLO26 với Mean Teacher framework kết hợp cùng mô-đun sử dụng GRL. Các luồng input (màu khác nhau) kết hợp cùng các hàm loss giúp hỗ trợ việc học bán giám sát

cho mô hình giáo viên. Nghiên cứu cũng huấn luyện mô hình học sinh một phần trên các mẫu không nhãn $\mathbf{I}^t$ này. Trong quá trình chưng cất, bằng cách chọn các hộp bao có xác suất cao từ các dự đoán của mô hình giáo viên làm nhãn giả, mô hình học sinh có xu hướng giảm phương sai trên miền đích và tăng cường tính bền vững của mô hình.

3.2 Ảnh tạo sinh chuyển đổi miền

Mặc dù nghiên cứu đã xây dựng thành công một mạng chưng cất cơ bản, có thể thấy trước rằng việc cập nhật trọng số của mô hình học sinh sẽ bị chi phối bởi các hình ảnh $\mathbf{I}^s$ trong miền nguồn. Ngược lại, mô hình giáo viên không tiếp xúc với hình ảnh nguồn và được dẫn dắt bởi các đặc trưng của miền đích. Nghiên cứu cần giảm thiểu những khác biệt miền ở cấp độ hình ảnh, vốn là nguyên nhân khiến hai mô hình bị thiên kiến theo các đầu vào hình ảnh đơn điệu của chúng.

Thay vì sử dụng các bộ dịch hình ảnh sinh đối nghịch (GAN-based) như CycleGAN [21] hay CUT [22], nghiên cứu đề xuất hai quy trình chuyển đổi miền dựa trên mô hình vật lý và mạng khử sương, nhằm tạo ra các cặp ảnh liên miền một cách hiệu

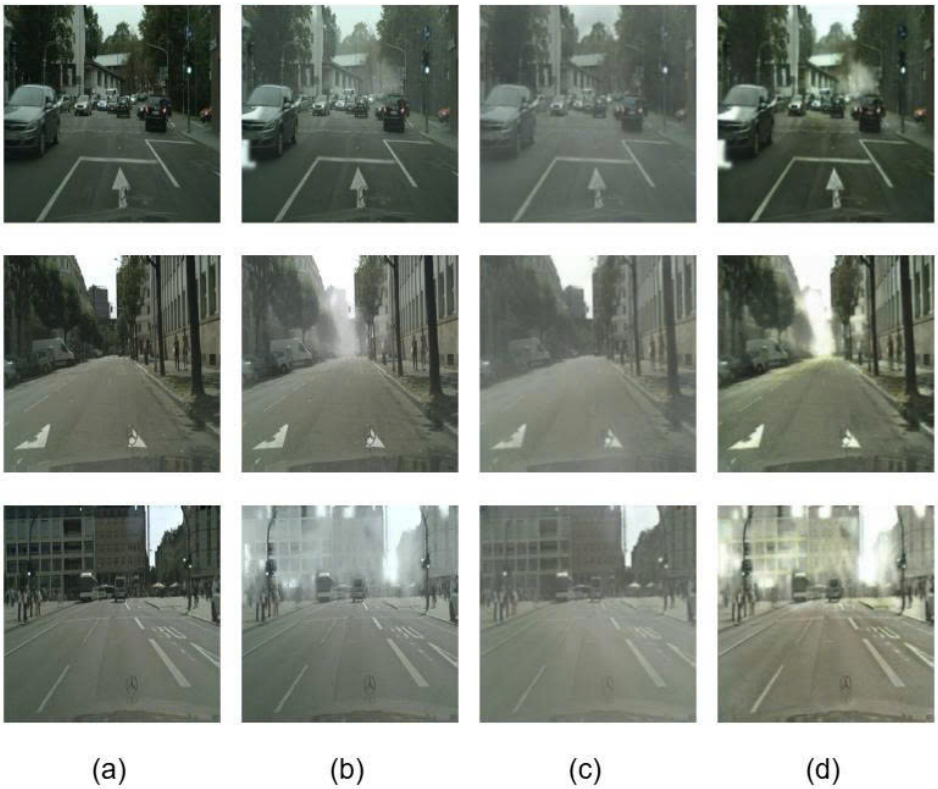

Hình 3.2: Ví dụ minh họa quá trình chuyển đổi miền, trong đó (a) là hình ảnh nguồn $\mathbf{I}^s$, (b) là hình ảnh đích thật $\mathbf{I}^t$, (c) là hình ảnh dạng đích được tổng hợp $\mathbf{I}^{sf}$, và (d) là hình ảnh dạng nguồn được khử sương $\mathbf{I}^{tf}$

quả và có kiểm soát hơn.

Tổng hợp ảnh dạng đích $\mathbf{I}^{sf}$ bằng mô hình tán xạ khí quyển. Để chuyển đổi hình ảnh nguồn $\mathbf{I}^s$ sang dạng đích có sương mù, nghiên cứu kết hợp mô hình ước lượng độ sâu DepthAnythingV2 [23] với mô hình vật lý tán xạ khí quyển. Cụ thể, với mỗi ảnh nguồn $\mathbf{I}^s$, DepthAnythingV2 được sử dụng để ước lượng bản đồ độ sâu $d(x)$ tương ứng. Cụ thể, mô hình sử dụng bộ mã hóa Vision Transformer ViT-L với kiến trúc DPT [24], được nạp trọng số tinh chỉnh trên tập dữ liệu ngoài trời Virtual KITTI 2 [25] với độ sâu tối đa $d_{\max} = 80\,\mathrm{m}$. Mô hình trả về bản đồ độ sâu *metric* $d(x) \in \mathbb{R}^{H \times W}$ tính bằng mét. Từ bản đồ độ sâu này, bản đồ truyền dẫn $t(x)$ được tính theo công thức:

$$t(x) = e^{-\beta \cdot d(x)} \tag{3.2}$$

trong đó β là hệ số tán xạ của môi trường. Hệ số tán xạ β được lấy mẫu ngẫu nhiên đồng đều trong khoảng $\beta \in [0.005, 0.015]$ cho mỗi ảnh, nhằm tăng tính đa dạng của

dữ liệu tổng hợp. Khoảng giá trị này tương ứng với mức độ sương mù nhẹ đến trung bình trên cảnh ngoài trời có độ sâu tới 80 m, sao cho vật thể ở khoảng cách xa vẫn còn nhận diện được nhưng bị suy giảm độ tương phản rõ rệt. Cuối cùng, ảnh tổng hợp dạng đích $\mathbf{I}^{sf}$ được tạo ra bằng mô hình tán xạ khí quyển:

$$\mathbf{I}^{sf}(x) = \mathbf{I}^{s}(x) \cdot t(x) + A\big(1 - t(x)\big) \tag{3.3}$$

trong đó A là cường độ ánh sáng môi trường xung quanh (atmospheric light). Thay vì sử dụng giá trị A cố định, nghiên cứu ước lượng ánh sáng khí quyển trực tiếp từ từng ảnh nguồn theo phương pháp dark channel prior của He et al. [26]. Cụ thể, với mỗi ảnh $\mathbf{I}^{s}$, kênh tối (dark channel) $J^{\text{dark}}(x)$ được tính bằng cách lấy giá trị nhỏ nhất trên cả ba kênh RGB trong một cửa sổ lân cận 15×15 pixel:

$$J^{\text{dark}}(x) = \min_{y \in \Omega(x)} \min_{c \in \{R,G,B\}} \mathbf{I}^{s}_{c}(y) \tag{3.4}$$

Tiếp theo, 0.1% điểm ảnh có giá trị dark channel cao nhất được chọn, và giá trị ánh sáng khí quyển $A \in \mathbb{R}^3$ được tính là trung bình RGB của các điểm ảnh đó trong ảnh gốc. Cách tiếp cận này cho phép A thích nghi với từng điều kiện chiếu sáng cụ thể thay vì giả định sương mù trắng đồng nhất. Cách tiếp cận này cho phép mô phỏng hiện tượng sương mù một cách có kiểm soát dựa trên hình học cảnh vật, thay vì phụ thuộc vào quá trình học của mạng sinh đối nghịch.

Tổng hợp ảnh dạng nguồn $\mathbf{I}^{tf}$ bằng mạng khử sương AODNet. Theo chiều ngược lại, để chuyển đổi hình ảnh đích $\mathbf{I}^{t}$ sang dạng nguồn không có sương mù, nghiên cứu áp dụng mạng khử sương AODNet [27]. AODNet học cách ước lượng trực tiếp ảnh sạch $J(x)$ từ ảnh có sương $\mathbf{I}^{t}$ thông qua một mạng tích chập nhẹ, không yêu cầu ước lượng trung gian bản đồ truyền dẫn hay ánh sáng môi trường một cách tường minh. Ảnh đầu ra $\mathbf{I}^{tf}$ thu được biểu diễn hình ảnh đích dưới điều kiện quan sát rõ ràng, gần với phân phối của miền nguồn.

Hai quy trình trên cho phép xây dựng các cặp ảnh liên miền $(\mathbf{I}^{s}, \mathbf{I}^{sf})$ và $(\mathbf{I}^{t}, \mathbf{I}^{tf})$ mà không cần huấn luyện thêm bất kỳ mạng sinh nào, đồng thời đảm bảo tính nhất quán về cấu trúc cảnh vật giữa ảnh gốc và ảnh được chuyển đổi. Ví dụ minh họa được trình bày ở hình 3.2.

3.3 Hàm mất mát chưng cất

Dựa trên cách triển khai của mô hình Mean Teacher, hàm mất mát để huấn luyện một mô hình có giám sát với tập dữ liệu nguồn có nhãn $\mathbf{D}_s$ có thể được viết như sau:

$$\mathbf{L}_{det}(\mathbf{I}^s, \mathbf{B}^s, \mathbf{C}^s) = \mathbf{L}_{det}^{o2m}(\mathbf{I}^s, \mathbf{B}^s, \mathbf{C}^s) + \mathbf{L}_{det}^{o2o}(\mathbf{I}^s, \mathbf{B}^s, \mathbf{C}^s) \tag{3.5}$$

trong đó $\mathbf{L}_{det}^{o2m}$ và $\mathbf{L}_{det}^{o2o}$ lần lượt là hàm mất mát phát hiện trên đầu *one2many* và đầu *one2one* của YOLO26 - một mô hình phát hiện đầu cuối không cần NMS. Mỗi thành phần bao gồm các hàm mất mát hộp bao, phân loại và hồi quy phân phối tọa độ tương ứng. Nghiên cứu chủ yếu giới thiệu về thích ứng miền không giám sát liên quan đến các hình ảnh miền đích không nhãn $\mathbf{D}_t$ trong các phần dưới đây.

Sau khi tạo ra $\mathbf{I}^{sf}$ và $\mathbf{I}^{tf}$, nhằm khắc phục sự sai lệch khác miền cho mô hình học sinh, nghiên cứu bổ sung một nhánh mới với đầu vào là các hình ảnh dạng đích $\mathbf{I}^{sf}$ (tham khảo luồng màu vàng trong Hình 3.1), và huấn luyện chúng cùng nhãn gốc như các hình ảnh nguồn $\mathbf{I}^s$ (tham khảo luồng màu đỏ trong Hình 3.1). Tương tự như Phương trình 3.5, hàm mất mát tương ứng được định nghĩa như sau:

$$\mathbf{L}_{det}(\mathbf{I}^{sf}, \mathbf{B}^{sf}, \mathbf{C}^{sf}) = \mathbf{L}_{det}^{o2m}(\mathbf{I}^{sf}, \mathbf{B}^{sf}, \mathbf{C}^{sf}) + \mathbf{L}_{det}^{o2o}(\mathbf{I}^{sf}, \mathbf{B}^{sf}, \mathbf{C}^{sf}) \tag{3.6}$$

Đối với mô hình giáo viên, để giúp mô hình học các đặc trưng cấp độ hình ảnh toàn cục của miền nguồn, nghiên cứu thay thế các hình ảnh đích đầu vào gốc $\hat{\mathbf{I}}^t$ bằng các hình ảnh giả dạng nguồn $\hat{\mathbf{I}}^{tf}$ (tham khảo luồng màu xanh dương trong Hình 3.1). Nhãn giả được sinh ra từ đầu *one2many* của mô hình giáo viên - đầu này cho kết quả dày và tin cậy hơn đầu *one2one* trong giai đoạn huấn luyện. Các hình ảnh đích không nhãn $\bar{\mathbf{I}}^t$ dùng cho việc huấn luyện mô hình học sinh được giữ nguyên (tham khảo luồng màu xanh lá trong Hình 3.1). Để tránh khuếch đại nhiễu từ nhãn giả qua cả hai đầu, hàm mất mát chưng cất chỉ áp dụng trên đầu *one2many*:

$$\mathbf{L}_{dis}(\mathbf{I}^{tf}, \mathbf{I}^t) = \mathbf{L}_{det}^{o2m}\big(\mathbf{I}^t,\ \mathbf{G_B}[\mathbf{F_B}(\mathbf{I}^{tf})],\ \mathbf{G_C}[\mathbf{F_C}(\mathbf{I}^{tf})]\big) \tag{3.7}$$

Trong đó, $\mathbf{F}_B(\cdot)$ và $\mathbf{F}_C(\cdot)$ là các nhánh dự đoán từ đầu *one2many* của mô hình giáo viên về hộp giới hạn và xác suất các lớp của ảnh $\mathbf{I}^{tf}$. $\mathbf{G}_B[\cdot]$ và $\mathbf{G}_C[\cdot]$ là bộ lọc

để giữ lại các nhãn đáng tin cậy nhất. Mô hình giáo viên còn thông qua việc cập nhật tham số EMA trong mô hình MT để không có xu hướng chỉ giỏi dự đoán các đối tượng trong miền đích một cách mù quáng. Đồng thời, quá trình huấn luyện mô hình học sinh sẽ dần tiếp cận miền đích thực tế với sự giám sát yếu (weak supervision) của các nhãn giả từ các dự đoán đã lọc của $\hat{\mathbf{I}}^{tf}$. Mặc dù không quá chính xác, các nhãn giả này đóng vai trò thay thế để thúc đẩy quá trình thích ứng dần dần cấp độ vật thể.

3.4 Hàm mất mát nhất quán

Mặc dù các cặp ảnh nguồn và ảnh kiểu đích ($\mathbf{I}^s$, $\mathbf{I}^{sf}$) được đưa vào mô hình học sinh có phân phối dữ liệu cấp độ cảnh (scene-level) khác nhau, chúng lại thuộc về cùng một không gian nhãn. Về mặt lý tưởng, một giả thuyết hợp lý là biểu diễn đặc trưng nội tại của mô hình học sinh khi nhận đầu vào từ cả hai miền cần phải nhất quán. Do đó, thay vì ràng buộc ở cấp đầu ra, nghiên cứu áp đặt ràng buộc trực tiếp lên không gian đặc trưng backbone bằng độ tương đồng cosine giữa hai luồng đặc trưng tương ứng. Nghiên cứu gọi đó là hàm mất mát nhất quán (consistency loss), được thiết lập như sau:

$$\mathbf{L}_{con} = 1 - \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \cos\Big(\phi_s(\mathbf{I}_i^{sf}),\ \phi_s(\mathbf{I}_i^{s})^{\dagger}\Big) \tag{3.8}$$

trong đó $\phi_s(\cdot)$ là đặc trưng backbone của mô hình học sinh, $\cos(\cdot,\cdot)$ là độ tương đồng cosine, và $(\cdot)^{\dagger}$ ký hiệu toán tử tách gradient (detach). Đặc trưng của ảnh nguồn thực $\phi_s(\mathbf{I}^s)$ được cố định làm neo, do đó gradient chỉ lan truyền qua nhánh $\mathbf{I}^{sf}$, buộc mô hình học cách trích xuất đặc trưng bất biến với phong cách miền. Hàm mất mát nhất quán dường như có thể khắc phục các thiên kiến khác miền về vật thể và phân loại. Hiệu quả của nó cũng sẽ được chứng minh qua các thực nghiệm.

3.5 Mô-đun học đảo ngược

Gradient Reversal Layer (GRL) là một thành phần kiến trúc mạng nơ-ron đặc biệt, được đặt giữa bộ trích xuất đặc trưng (feature extractor) và bộ phân loại

miền (domain classifier). Mục tiêu của GRL là đạt được thích ứng miền (domain adaptation) bằng cách tạo ra các đặc trưng f thỏa mãn đồng thời:

1. Tính phân biệt: Tối thiểu hóa lỗi dự đoán nhãn lớp trên miền nguồn.
2. Tính bất biến miền: Tối đa hóa lỗi của bộ phân loại miền, làm cho phân phối đặc trưng của miền nguồn và miền đích trở nên không thể phân biệt được.

Lan truyền xuôi (Forward Propagation) GRL hoạt động như một phép biến đổi đồng nhất (identity transform), truyền tín hiệu đầu vào đi tiếp mà không thay đổi:

$$R_\lambda(\mathbf{x}) = \mathbf{x}$$

. Lan truyền ngược (Backpropagation) GRL đảo ngược gradient bằng cách nhân với một hằng số âm trước khi truyền về các lớp trước đó:

$$\frac{\partial R_\lambda}{\partial \mathbf{x}} = -\lambda \mathbf{I}$$

, trong đó $\mathbf{I}$ là ma trận đơn vị.

Trong quá trình cập nhật tham số bộ trích xuất đặc trưng θ_f, nhờ GRL, gradient của loss phân loại miền (L_d) bị đảo dấu, dẫn đến quy tắc cập nhật:

$$\theta_f \leftarrow \theta_f - \mu \left(\frac{\partial L_y}{\partial \theta_f} - \lambda \frac{\partial L_d}{\partial \theta_f} \right) \tag{3.9}$$

Trong đó L_y là hàm mất mát của nhãn, L_d là hàm mất mát của miền, như vậy θ_f được cập nhật theo công thức để học theo GRL. Điều này buộc bộ trích xuất đặc trưng học cách làm hỏng bộ phân loại miền trong khi vẫn giữ khả năng dự đoán nhãn chính xác.

3.6 Tối ưu tổng quan

Kiến trúc của FusionDA được minh họa trong Hình 3.1. Các ảnh mang phong cách miền đích $\mathbf{I}^{sf}$ và ảnh mang phong cách miền nguồn $\mathbf{I}^{tf}$ được tạo bởi các mô hình CUT tương ứng đã được huấn luyện trước. Trong quá trình suy luận, nghiên cứu chỉ cần sử dụng mô hình học sinh đã được huấn luyện tinh chỉnh và lấy ảnh miền đích làm đầu vào duy nhất. Mô hình có thể được huấn luyện theo phương thức đầu cuối bằng cách tối ưu hóa đồng thời tất cả các hàm mất mát liên quan. Hàm mất mát tổng thể được thiết lập như sau:

$$\mathbf{L} = \mathbf{L}_{det}(\mathbf{I}^s) + w_{sf}(t) \cdot \mathbf{L}_{det}(\mathbf{I}^{sf}) + \alpha \cdot \mathbf{L}_{dis}(\mathbf{I}^{tf}, \mathbf{I}^t) + \beta \cdot \mathbf{L}_{con} + \mathbf{L}_{domain} \tag{3.10}$$

trong đó α và β là các siêu tham số cân bằng (trade-off hyper-parameters) được xác định thông qua các thực nghiệm; $w_{sf}(t)$ là trọng số suy giảm tuyến tính theo tiến trình huấn luyện, nhằm hạn chế dần ảnh hưởng của nhiễu phong cách CUT lên giai đoạn cuối; và $\mathbf{L}_{domain}$ là hàm mất mát đối nghịch từ mô-đun GRL.

Chương 4

Thực nghiệm và đánh giá

4.1 Câu hỏi nghiên cứu

4.2 Dữ liệu và thiết lập thực nghiệm

Bộ dữ liệu Cityscapes [28] là bộ dữ liệu gồm 2975 ảnh huấn luyện và 500 ảnh xác thực, ghi lại các cảnh đường phố đô thị trong điều kiện thời tiết bình thường, được thu thập từ 50 thành phố. Foggy Cityscapes [4] được tạo ra bằng cách bổ sung sương mù nhân tạo vào các ảnh trong Cityscapes. Do đó, hai bộ dữ liệu này có cùng cách chia tập huấn luyện và xác thực. Trong quá trình huấn luyện, sử dụng tập huấn luyện của Cityscapes và tập huấn luyện không gán nhãn của Foggy Cityscapes; còn việc đánh giá được thực hiện trên tập xác thực của Foggy Cityscapes.

Cài đặt

4.3 Các phương pháp đối sánh

4.4 Độ đo đánh giá

Nghiên cứu sử dụng độ đo Mean average precision (mAP) như một công cụ chính và phổ biến. Khi đánh giá các mô hình phát hiện đối tượng, ta quan tâm không chỉ tới việc phân lớp (class) mà còn tới việc xác định chính xác vùng bounding box trùng với đối tượng thật. Do đó, các chỉ số đơn giản như accuracy với classification không còn phù hợp. Thay vào đó, người ta sử dụng các mức đo dựa trên precision, recall và độ chồng lắp (IoU).

Giả sử một dự đoán được coi là true positive nếu và chỉ nếu: (i) lớp dự đoán khớp lớp thật, và (ii) chỉ số Intersection over Union (IoU) giữa bounding-box dự đoán và ground-truth không nhỏ hơn một ngưỡng cố định t_{IoU}. Các dự đoán đúng như vậy được tính là TP; dự đoán sai hoặc không khớp box / lớp được xem là false

positive (FP); các object thật mà không được phát hiện là false negative (FN).

Precision và recall được định nghĩa như sau:

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}.$$

Khi thay đổi ngưỡng confidence của mô hình, ta thu được nhiều cặp (precision, recall), từ đó có thể vẽ đường cong Precision–Recall (PR curve). Giá trị

$$\text{AP} = \int_0^1 P(r)\, dr$$

được gọi là Average Precision - diện tích dưới PR curve, thể hiện hiệu năng tổng quát của mô hình đối với một lớp trong mọi ngưỡng.

Cuối cùng, nếu có tổng cộng N lớp, ta định nghĩa:

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^{N} AP_i.$$

Tùy theo thiết lập đánh giá, người ta có thể dùng một ngưỡng IoU cố định (ví dụ $t_{IoU} = 0.5$, ghi mAP@0.5), hoặc trung bình qua nhiều ngưỡng IoU (ví dụ từ 0.5 đến 0.95 với bước 0.05), để có cái nhìn toàn diện hơn về khả năng phát hiện và định vị chính xác của mô hình.

Vì vậy mAP trở thành thước đo tiêu chuẩn giúp so sánh các mô hình object detection, phản ánh đồng thời độ chính xác phân lớp, độ đầy đủ phát hiện (recall), và chất lượng định vị bounding box.

4.5 Kết quả thực nghiệm

4.6 Phân tích và thảo luận kết quả

Kết luận

Tóm tắt bài toán, giải pháp và các kết quả đạt được

Tài liệu tham khảo

[1] Vishwanath A Sindagi, Poojan Oza, Rajeev Yasarla, and Vishal M Patel. Prior-based domain adaptive object detection for hazy and rainy conditions. In *European Conference on Computer Vision*, pages 763–780. Springer, 2020.

[2] Jinlong Li, Runsheng Xu, Jin Ma, Qin Zou, Jiaqi Ma, and Hongkai Yu. Domain adaptive object detection for autonomous driving under foggy weather. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pages 612–622, 2023.

[3] Zhengxi Zhang, Liang Zhao, Yunan Liu, Shanshan Zhang, and Jian Yang. Unified density-aware image dehazing and object detection in real-world hazy scenes. In *Proceedings of the Asian conference on computer vision*, 2020.

[4] Christos Sakaridis, Dengxin Dai, and Luc Van Gool. Semantic foggy scene understanding with synthetic data. *International Journal of Computer Vision*, 126(9):973–992, 2018.

[5] Mahi Aminu, Chisom Chibuike, Fatimo Adebanjo, Omokolade Awosanya, and Samuel Oyeneye. Effect of domain generalization techniques in low resource systems. *arXiv preprint arXiv:2510.27512*, 2025.

[6] David Acuna, Marc T Law, Guojun Zhang, and Sanja Fidler. Domain adversarial training: A game perspective. *arXiv preprint arXiv:2202.05352*, 2022.

[7] Liang Chen, Jianhong Han, and Yupei Wang. Datr: Unsupervised domain adaptive detection transformer with dataset-level adaptation and prototypical alignment. *IEEE Transactions on Image Processing*, 2025.

[8] Yecheol Kim, Junho Lee, Changsoo Park, Hyoung won Kim, Inho Lim, Christopher Chang, and Jun Won Choi. Semi-supervised domain adaptation using target-oriented domain augmentation for 3d object detection. *IEEE Transactions on Intelligent Vehicles*, 2024.

[9] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05)*, volume 1, pages 886–893. Ieee, 2005.

[10] Pedro F Felzenszwalb, Ross B Girshick, David McAllester, and Deva Ramanan. Object detection with discriminatively trained part-based models. *IEEE transactions on pattern analysis and machine intelligence*, 32(9):1627–1645, 2009.

[11] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 25, 2012.

[12] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 779–788, 2016.

[13] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2117–2125, 2017.

[14] Shu Liu, Lu Qi, Haifang Qin, Jianping Shi, and Jiaya Jia. Path aggregation network for instance segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 8759–8768, 2018.

[15] Abolfazl Farahani, Sahar Voghoei, Khaled Rasheed, and Hamid R Arabnia. A brief review of domain adaptation. *Advances in data science and information engineering: proceedings from ICDATA 2020 and IKE 2020*, pages 877–894, 2021.

[16] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.

[17] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario March, and Victor Lempitsky. Domain-adversarial training of neural networks. *Journal of machine learning research*, 17(59):1–35, 2016.

[18] Yuhua Chen, Wen Li, Christos Sakaridis, Dengxin Dai, and Luc Van Gool. Domain adaptive faster r-cnn for object detection in the wild. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3339–3348, 2018.

[19] Kuniaki Saito, Yoshitaka Ushiku, Tatsuya Harada, and Kate Saenko. Strong-weak distribution alignment for adaptive object detection. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 6956–6965, 2019.

[20] Antti Tarvainen and Harri Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. *Advances in neural information processing systems*, 30, 2017.

[21] Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Proceedings of the IEEE international conference on computer vision*, pages 2223–2232, 2017.

[22] Taesung Park, Alexei A Efros, Richard Zhang, and Jun-Yan Zhu. Contrastive learning for unpaired image-to-image translation. In *European conference on computer vision*, pages 319–345. Springer, 2020.

[23] Lihe Yang, Bingyi Kang, Zilong Huang, Zhen Zhao, Xiaogang Xu, Jiashi Feng, and Hengshuang Zhao. Depth anything v2. *Advances in Neural Information Processing Systems*, 37:21875–21911, 2024.

[24] René Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 12179–12188, 2021.

[25] Yohann Cabon, Naila Murray, and Martin Humenberger. Virtual kitti 2. *arXiv preprint arXiv:2001.10773*, 2020.

[26] Kaiming He, Jian Sun, and Xiaoou Tang. Single image haze removal using dark channel prior. *IEEE transactions on pattern analysis and machine intelligence*, 33(12):2341–2353, 2010.

[27] Boyi Li, Xiulian Peng, Zhangyang Wang, Jizheng Xu, and Dan Feng. Aod-net: All-in-one dehazing network. In *Proceedings of the IEEE international conference on computer vision*, pages 4770–4778, 2017.

[28] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele.

The cityscapes dataset for semantic urban scene understanding. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3213–3223, 2016.